

MLLM を用いた音響・映像統合解析に基づくオブジェクト同定手法の提案

A2278812 多田 大地

指導教員 川端 亮

1. 研究背景と課題

昨今、大規模言語モデル（以下、LLM）は著しい発展を遂げており、映像や音声といった複数のモダリティを統合的に処理して高度な文脈理解を実現するマルチモーダル大規模言語モデル（以下、MLLM）へと進化している。現状の MLLM 研究は静止画の理解に焦点が置かれる傾向にあり、動画を用いた連続的な視覚データを処理する能力は探求されていない¹。既存の研究の多くは、モデル自体の新規構築や基礎的な性能評価に留まっており、実用を見据えた評価手法そのものも確立されていないのが実情である。特に AI で、動画内の空間的な音源証拠²の提示を行う研究は少数存在するが、商用 MLLM を対象とした検証は十分になされていない。加えて、動画解析における精度評価後の事後検証および継続的な改善プロセスに関する研究は前例が乏しい。

2. 研究目的

本研究の主目的は、動画から音源を高度に特定する解析システムの構築である。その達成のため、以下の2点を目標とした。

第一に、動画解析を行う MLLM の実用性と精度を向上させるため、ユーザーフィードバックを直接反映する UI を設計・構築することである。

第二に、商用 LLM へのファインチューニング(以下、FT)導入による音源特定能力の向上を、定量的に検証することである。これらを通じ、現場での継続的な精度改善サイクルを備えた、動画解析アプリケーションとしての手法を確立することを目指す。

3. 本研究のアプローチ

上記の目的を達成するため、本研究では以下の手法を採用する。動画内の事象解釈において、単に音声や映像を個別に扱うの

ではなく、オブジェクトと音声が時間的に一致することを示し、その発生源と原因を紐づけることができれば、解釈の曖昧性を排除した証拠提示が可能となる。

そこで本研究では、商用 MLLM を基盤とし、人間が AI の推論結果（イベント名、発生源、タイムスタンプ、推論根拠）に対して修正を加えることができるインターフェースを構築する。このシステムを通じ、ユーザーが修正したデータ教師データとして蓄積し、それを用いて教師あり FT を行うことで、モデルを特定の利用環境やタスクへ適応させるアプローチをとる。

4. システム構成と評価手法

本研究では、動画から音源を特定するためのマルチモーダル LLM の精度向上と評価を目的とした Human-in-the-loop システムを開発した。図1の通り、本システムは、AIの推論結果に対しユーザーが修正を加えることで教師データを作成し、即座に精度評価及びモデルの FT を行う機能を備える。




図1 システム構成

さらに、蓄積された評価データを統合・分析することで、AIの誤り傾向の特定やモデル間の性能比較検証が一貫して行われる。評価手法として、イベント検出結果を正解、誤認、過剰検知、検出漏れの4区分に分類する新たな基準を導入した。特にAIが出力する発生源および推論根拠の文章については、オブジェクト、属性、動作、音の4要素へと構造化し、各々の正誤判定を行った。これらの指標を用いて精度を算出し、モデ

ルの精度を定量的に評価・比較した。

5. UI 設計

本システムは、動画閲覧と解析結果の検証・修正作業を単一画面内で完結させるアプリケーションとして設計した。図2の通り、画面構成は、動画プレーヤーと操作パネル、AIが抽出した時系列イベントリスト(テーブル)を配置し、各イベント行には、タイムスタンプに応じた動画の自動シーク機能や、図3のように Cloud Vision API による物体検出枠を組み込んだ。



図2 アプリケーション画面



図3 オブジェクト同定

また、別画面において修正した結果で FT の実施や、モデル毎の評価結果を比較する機能を実装した。

6. 実験手順

本研究では、動画・音声解析における MLLM の適応能力を検証するため、多様な環境下で撮影された動画群を用いた比較実験を行った。実験手順として、まず Gemini 2.5 Pro(ベースモデル)による推論結果を人手により修正・確定することで教師データセットを構築し、同時にベースモデルの精度を測定した。次に、構築したデータセットを用いて同モデルに FT を施し、学習モデルを作成した。最後に、この学習済みモ

デルを用いて同一動画群に対する再評価を行い、ベースモデルとの定量的な精度比較を通じて、学習による認識精度の向上効果を検証した。具体的には、道路上で撮影した動画を用いて、FT を実施し、評価用動画セットに対し学習済みモデルとベースモデルの精度を比較した。

7. 実験結果

ベースモデルに対し、学習済みモデルは検出漏れ率が 14.3% から 9.9% に下がり、イベントの検出精度の向上が示された。イベントが不正確に記述された割合についても、38.5% から 35.4% に向上した。

8. おわりに

本システムは、LLM による映像を用いたオブジェクト同定を行い、FT の有用性を検証した。今後、本システムの改良により、映像と音声を因果推論により動画コンテキストの解釈の向上を目指す。

9. 今後の課題

音響イベントの記述の正確性について大きな改善が見られず、物体検出枠が正確に描画されないケースが確認された。したがって、FT の手法や教師データ数、オブジェクトの空間的定位の精度の改善が望まれる。

10. 参考文献

- (1) Fu C, Dai Y, Luo Y, et al. Video-mme: The first-ever comprehensive evaluation benchmark of multi-modal llms in video analysis. 2025:24108–24118.
- (2) Senocak A, Oh T, Kim J, Yang M, Kweon IS. Learning to localize sound source in visual scenes. 2018:4358–4366.