

MLLMを用いた音響・映像統合解析に 基づくオブジェクト同定手法の提案

上智大学理工学部 情報理工学科

A2278812 多田大地

目次


1. 研究概要
2. 研究背景
3. 関連研究
4. 研究目的
5. 研究アプローチ
6. システム構成
7. ユーザーインターフェース
8. 評価実験
9. 今後の展望

1. 研究概要

AI(MLLM)で、動画内から音源である物体を特定



ファインチューニングで特定の精度を上げる

音源	修正(音源)	推論根拠
赤い車		動画の開始と同時に、画面左から赤い車が現れ、右へと走行していく。この車の動きに合わ



2. 研究背景 ①MLLMの発展

マルチモーダル大規模言語モデル(MLLM)とは：テキスト，画像，音声，動画といった，
複数の異なるデータ形式を処理するモデル

- 視覚情報，音響情報を，他の言語と同様の文脈で解釈
 ➡ 通常のLLMに比べて複雑なタスクを実行

2. 研究背景 ②音源特定の課題

MLLM等のAI研究は静止画理解が中心

- 動画理解に関する研究もあるが、相対的に少ない
 - 音源を特定する研究(音源定位など)も同様
- 精度評価後、事後学習など精度改善のプロセスに関する研究事例の不足

3. 関連研究


**“Bubogpt: Enabling visual grounding in multi-modal
llms,”**(2023)
(Zhao, Lin et al.)

- 視覚，音声，言語に加え，テキストと画像領域を紐づける
- 入力されたテキストエンティティに対応する画像領域を特定
- 整合・不整合のペアを含む指示データセットによる学習

4. 研究目的

- 動画内の音源オブジェクトを,
商用MLLM(Gemini 2.5 Pro)により特定
(オブジェクト同定)
- 学習(ファインチューニング)によるオブジェクト同定
の精度向上の検証

5. 研究アプローチ



提案手法の学習サイクル

- フィードバックを用いたHuman-in-the-Loop型の継続的改善サイクル
- MLLMにおける事後学習システムの実装，効果検証
- GUI操作が可能なアプリケーションで実装

6. システム構成

システムの流れ

統合解析(Gemini 2.5 Pro) . . .

動画から音が発生した事象(音響イベント)を出力

1. 評価・教師データ作成 . . .

出力されたイベントを手で修正し、教師データの作成
修正前後を比較し精度評価の実施

2. ファインチューニング . . .

教師データをファインチューニングで学習し、
学習済みモデルを作成して同様に解析

■学習済みモデルとベースモデルで精度比較

6. システム構成

解析ロジック(Gemini 2.5 Pro)

以下のルールでオブジェクトを出力するようプロンプト指示

- 音の発生した時系列順に,
映像内で物体が音を発している出来事(音響イベント)を出力
- 主にリストに含める内容 . . .
タイムスタンプ, 音源 推論根拠(その音源を特定した理由)
- 推論根拠を物体, 属性, 動作, 音, に分割して構造化データを構成

※画面外の音源は評価指標(後述)から排除

6. システム構成

バウンディングボックスの描画 (視覚補助ツール)


- オブジェクトを赤枠で囲む
- Cloud Vision API . . .
 - 物体検出に特化して学習された専用ツール
 - 音源オブジェクトを空間的に可視化



6. システム構成

代表フレームの抽出, 物体検出

Geminiのイベントのタイムスタンプに基づき, 動画からフレームを一秒あたり17枚抽出し, Cloud Vision APIが検出



Cloud Vision APIでオブジェクトが検出されたフレーム(赤)のうち, 最大で中央の10枚を描画

6. システム構成

Gemini(オブジェクトを検出)

Geminiが日本語で物体を出力し，英訳
例：白い自動車 ⇒ White car



さらに，一般的な英単語に変換
例：White car ⇒ Car



Cloud vision API(オブジェクトと位置の検出)

全フレームに存在するオブジェクトを全て検出
→ 英単語で出力(仕様)
例：Car

完全一致したワード，又は包含関係のあるワードを検出



PythonのPillowライブラリで，条件に一致したオブジェクトを**赤色**
それ以外を**黄色**のバウンディングボックスで囲んで描画

6. システム構成

システムアーキテクチャ

- 本研究では、動画入力から解析・評価まで一貫して行うWebベースのシステムを構築

システム構成：

1. フロントエンド/バックエンド
 - Flask, HTML, CSSを用いたWebアプリケーション
 - 解析, 出力結果の表示, 評価などをユーザー操作で実施
2. 解析/学習基盤, データ管理層
 - クラウド上のLLMを用いて動画解析を実行
 - 動画データ, 教師データの管理

6. システム構成

解析/学習プラットフォームの構成

1. Vertex AI . . .

- Google Cloudの統合MLプラットフォーム
- モデルの呼び出し, 学習, デプロイが可能
- Gemini 2.5 Proによる動画解析, 教師データを用いたFTを実施

2. Google Cloud Storage(GCS) . . .


- Google Cloudのストレージサービス
- 動画ファイルや教師データ, 学習済みモデルの保存に活用
- Vertex AIと連携し, 動画や教師データ等を読み込む

7. ユーザーインターフェース

- 解析タブ/評価タブで出力結果の修正、評価が可能
- 出力結果の修正、修正前・修正後の比較が可能
- ファインチューニングに用いる修正結果を保存


番号	タイムスタンプ	修正(時間)	クリップ再生	イベント名	修正(イベント名)	音源	修正(音源)	推論根拠	修正(推論根拠)
1	00:00-00:01 行挿入	M:SS-M:SS	ポップアップ再生	Car driving		赤い車		動画の開始と同時に、画面左から赤い車が現れ、右へと走行している。この	

7. ユーザーインターフェース

番号	タイムスタンプ	修正(時間)	クリップ再生	イベント名	修正(イベント名)	音源	修正(音源)	推論根拠	修正(推論根拠)	不正解	画面外の音源	削除
1	00:00-00:01 行挿入	M:SS-M:SS	ポップアップ再生	Car driving		赤い車		動画の開始と同時に、画面左から赤い車が現れ、右へと走行していく。この車の動きに合わせて、エンジン音とタイヤの走行音がはっきりと聞こえる。	 ☐ AI判定を優先	☐ ☒ CMH	☐	削除

Gemini (青枠) - 赤い車: (廃止されました)

Vision API (赤枠) - 赤い車:


✓ car

8. 評価実験

- 対象：道路環境の動画
- データセット：
学習用の動画50枚による教師データ
評価用の動画20枚による評価データ
- 比較対象：
 - ①ベースモデル(Gemini 2.5 Pro)
 - ②学習済みモデル(学習用データセット50枚を学習)

8. 評価実験

パラメータ	意味
正解数	正確に記述されたイベント数
不正解数	不正確に記述されたイベント数
過剰検知数	存在しないイベント数
検出漏れ数	AIが見逃したイベント数

検出されたイベント数	+	+
実際のイベント数	+	+

8. 評価実験

モデルの精度評価の指標

評価指標による定量化：

- 不正解率 = $\frac{\text{過剰検知数} + \text{不正解数}}{\text{検出数}}$ (過剰検知数 + 不正解数) / 検出数

- 検出漏れ率 = $\frac{\text{数}}{\text{実際のイベント数}}$

- 過剰 = $\frac{\text{過剰検知数}}{\text{検出数}}$ 過剰検知数 / 検出数

8. 評価実験

誤りタイプの分類

- $\left\{ \begin{array}{l} AI \\ 構造化 \end{array} \right.$
- 構造化・・・
オブジェクト, 属性 動作 音
の4要素に分類
- 誤りタイプの取得
例：動作方向が誤っていた場合,
動作誤認へ分類

項目	正解	AI予測	判定
オブジェクト	トラック	トラック	○
属性	緑色の幌で荷台が覆われた 白いトラック	緑色の幌で荷台が覆われた 白いトラック	○
動作	画面 <u>左</u> から <u>右</u> へ走行	画面 <u>右</u> から <u>左</u> へ走行	×
音	低いディーゼルエンジンの 音とタイヤの走行音	低いディーゼルエンジンの 音とタイヤの走行音	○

8. 評価実験

ファインチューニングの実施

- Vertex AIの形式に合わせJSONL
ファイルを作成
➡ファインチューニング
- 複数の動画で作成した
教師データをまとめて選択
➡チューニングジョブへ投入

☐	日時	動画ファイル	モデル	F1	操作
☐	2025-12-31 17:50	IMG_4811.mov	projects/85451025337/ locations/us-central1/ models/350340358639 6618752	1.000	再編集
☐	2025-12-31 17:48	IMG_4808.mov	projects/85451025337/ locations/us-central1/ models/350340358639 6618752	1.000	再編集
☐	2025-12-31 17:44	IMG_4811.mov	gemini-2.5-pro	1.000	再編集
☐	2025-12-31 17:34	IMG_4808.mov	gemini-2.5-pro	1.000	再編集

UIに表示した教師データ一覧

8. 評価実験

指標	ベースモデル(A)	学習済みモデル(B)	A-B
不正解率(Mis)	0.385	0.354	-0.031
(過剰検知率)	0.0	0.0	0.0
検出漏れ率	0.143	0.099	-0.044
物体の誤認割合	0.372	0.354	-0.018
属性の誤認割合	0.026	0	-0.026
動作の誤認割合	0.026	0.024	0.002
音の誤認割合	0.013	0.024	+0.011

8. 評価実験

考察(検出精度, 記述精度)

検出漏れ率が**14.3%→9.9%**

■わずかに検出漏れの割合が改善する傾向が見られた

- 特定の環境下において音響データをイベントの対応付けに関して、ベースモデルよりやや強く学習した可能性

不正解率が**38.5%→35.4%**

- 両モデルともに動作誤認数が多い結果となった
- 記述の軽微なニュアンス等の違いによって正誤が分かれた事例もあり、強い改善傾向があるとは言い切れない

補足：空間推論の限界

- Cloud Vision APIでは、オブジェクトの属性や詳細な情報まで考慮して特定することが不可能
- Geminiによる意味的一致
 - ▶ 包含関係が適切に判定されないケースがある

9. 今後の展望

- 座標学習の導入：
Gemini 2.5 に対し，特定フレームにおける座標を学習させる
ことでオブジェクトの認識精度自体を向上させる
▶空間定位の精度にも繋げる
- GPT-4o等，他のMLLMモデルとの性能比較
- 学習パラメータを変化させて検証
- 異なる環境下で実験し，ドメイン特化モデルとしての
性能を検証
- 教師データと評価データの動画サンプルの追加

参考文献

- (1)IBM"視覚言語モデル (VLM) とは," vol. 2026, no. Jan 6<https://www.ibm.com/jp-ja/think/topics/vision-language-models#318643376>.
- (2)Google"Gemini 2.5 で動画理解の新たな地平を切り開く," Google for Developers, vol. 2026, no. Jan 6<https://developers.googleblog.com/ja/gemini-2-5-video-understanding/>.
- (3)Fu, Dai, "Video-mme: The first-ever comprehensive evaluation benchmark of multi-modal llms in video analysis," pp. 24108–24118.
- (4)Arandjelovic and Zisserman, "Look, listen and learn," pp. 609–617.
- (5)Senocak, Oh, "Learning to localize sound source in visual scenes," pp. 4358–4366.
- (6)Zellers, Lu, "Merlot reserve: Neural script knowledge through vision and language and sound," pp. 16375–16387.
- (7)Zhang, Li, "Video-llama: An instruction-tuned audio-visual language model for video understanding," arXiv preprint arXiv:2306.02858.
- (8)Mo and Morgado, "A unified audio-visual learning framework for localization, separation, and recognition," pp. 25006–25017.

参考文献

- (9)Um, Kim, "Object-aware Sound Source Localization via Audio-Visual Scene Understanding," pp. 8342–8351.
- (10)Zhao, Lin, "Bubogpt: Enabling visual grounding in multi-modal llms," arXiv preprint arXiv:2307.08581.
- (11)Ouyang, Wu, "Training language models to follow instructions with human feedback," Advances in neural information processing systems, vol. 35, pp. 27730–27744.
- (12)Hsieh, Li, "Distilling step-by-step! outperforming larger language models with less training data and smaller model sizes," pp. 8003–8017.
- (13)Wei, Wang, "Chain-of-thought prompting elicits reasoning in large language models," Advances in neural information processing systems, vol. 35, pp. 24824–24837.
- (14)Min, Krishna, "Factscore: Fine-grained atomic evaluation of factual precision in long form text generation," pp. 12076–12100.

参考文献

- (15) Bolya, Foley, "Tide: A general toolbox for identifying object detection errors," pp. 558–573.
- (16) Ullah and Mohanta, "Thinking hallucination for video captioning," pp. 3654–3671.
- (17) Nakada, Saito, "Hallucination Localization in Video Captioning," arXiv preprint arXiv:2510.25225.
- (18) Sung-Bin, Hyun-Bin, "Avhbench: A cross-modal hallucination benchmark for audio-visual large language models," arXiv preprint arXiv:2410.18325.
- (19) Google "Generative AI on Vertex AI," <https://docs.cloud.google.com/vertex-ai/generative-ai/docs/vertex-ai-zero-data-retention>, vol. 2026, no. -01-14, -12-11 UTC.

ご清聴ありがとうございました